

25-1 Data Science Lab Modeling Project – 추천시스템 팀 보고서

11기 한은결 | 12기 김민규 | 13기 김선기, 박세현, 정주은

1. Introduction

추천 시스템은 선택지가 많고, 사용자마다 분명한 취향이 존재하나, 이를 구체적인 기준으로 설명하거나 표현하기 어려운 경우에 특히 효과적으로 작동한다. 아이템의 수가 방대하고, 속성의 구조가 복잡하며, 소비자의 사전 지식이 제한적인 도메인에서, 추천 시스템은 탐색 비용을 줄이고 사용자 만족도를 높이는 데 중요한 역할을 하기 때문이다. 이러한 점에서 와인은 추천 시스템 적용에 매우 적합한 도메인이라고 판단했다. 와인은 생산지, 품종, 와이너리, 가격, 향미 등 다층적인 속성 정보를 갖고 있지만, 일반 소비자들은 이들 속성 간의 차이를 명확히 구분하거나 자신의 취향을 정확히 언어로 설명하기 어렵기 때문이다.

본 프로젝트에서는 실제 와인 플랫폼인 Vivino에서 크롤링한 사용자-와인 리뷰 데이터를 기반으로 추천 모델을 구성하였다. 그러나 수집된 리뷰 데이터는 사용자별 상호작용이 매우 희소(sparse)하다는 문제가 존재하였다. 대부분의 사용자들이 극히 일부의 와인에 대해서만 리뷰를 남긴 상태였고, 이는 전통적인 협업 필터링 기반 모델이나 단순한 matrix factorization 기법으로는 충분한 성능을 내기 어려운 환경이었다.

이러한 sparsity 문제를 해결하고자, 본 프로젝트는 LightGCN, MCCF, MKR, KGAT, G-Former 등 다양한 구조의 추천 모델들을 적용하고 성능을 비교하는 방식으로 진행되었다. 각 모델은 지식 그래프 통합 방식, 멀티모달 정보 활용 여부, 자기지도학습(self-supervised learning) 적용 여부 등에서 서로 다른 특성을 가지며, 이를 통해 희소하고 복잡한 와인 추천 데이터에 어떤 접근이 보다 효과적인지를 실험적으로 검증하고자 하였다. 본 프로젝트는 단순히 하나의 모델을 구현하는 데 그치지 않고, 도메인 특화 데이터에 적합한 모델 구조와 학습 방식이 무엇인지 탐색하는 데 그 목적이 있다.

2. Pipeline

2-1. Dataset

와인 데이터의 경우 해외 와인 판매 및 리뷰 관련 사이트인 [Vivino](https://www.vivino.com) 웹사이트에서 리뷰와 와인 데이터를 크롤링하여 구축하였다. 이때 미국에서 구매 가능한 와인들을 기준으로 리뷰와 와인을 집계하였으며, 리뷰수 상위 500명의 리뷰어들의 레이팅 정보를 수집하였다. 그 결과 총 299,646개의 와인이 선정되었다.

user	The Holy Trinity Red Blend 2018	Pinot Noir 2012	Pomerol 2019	Brut Rosé Champagne N.V.	Topography 2014
James Pilachowski		4.0		4.5	
Alexander Ross		2.0	3.5	3.5	
-"Paul Neira"-			4.5	4.5	
Tom Colby					
Cs Runner				3.5	
Ming				4.0	4.1

Figure 1. Vivino 사이트에서 수집한 와인 리뷰 데이터 중 일부.

하지만, 해당 와인 데이터의 경우 여러 측면에서 그대로 사용하기에 문제점을 가지고 있다. 우선 레이팅이 4점에서 5점 사이에 지나치게 몰려있는 특성을 가지고 있었다. 이에 따라 해당 프로젝트에서는 레이팅 점수에 로그 변환을 가한 후 정수화하여 일부 모델에서 사용 가능할 경우 해당 변환을 가했다. 추가로 user와 item (여기서는 와인) 간의 sparsity가 기존 추천시스템 관련 데이터와 달리 지나치게 sparse한 모습을 보였다. 이는 개인 별로 마시는 와인의 선택지가 매우 다양하다는 점에서 기인한 것으로, 실제로 데이터를 분석했을 때 2개 이하의 리뷰가 있는 와인들을 제외할 경우 36,140개의 와인이, 3개 이하를 모두 제거할 경우 19,190개의 와인이 남아, 해당 프로젝트에서는 2개 이하의 리뷰가 있는 와인들을 제거한 데이터셋을 사용하여 모델링을 진행하였다.

2-2. Models

A. LightGCN (SIGIR 2020)¹




Figure 2. LightGCN의 전체 아키텍처.

¹ <LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation>, He et al., 2020.

기존 GCN의 문제점으로 지적받던 비효율성, 그리고 Depth가 깊어질수록 오버피팅이 급격하게 발생한다는 점을 해결하기 위해 전체적인 아키텍처를 간소화시킨 LightGCN은 Vanilla GCN에서 Feature Transformation, Nonlinear Activation 부분을 제거하고 Neighbor Aggregation만 남겨두었다. 해당 모델에서는 최초 layer의 임베딩 벡터만이 유일한 학습되는 파라미터 들이며, 이외의 부분은 학습이 되지 않아, 그 파라미터의 수가 적다는 특징을 가지고 있다. Layer Combination을 통해 over-smoothing 현상을 해결하고, nonlinear activation을 역할을 대신해 연결성 구조에 대한 정보를 반영할 수 있게 만들어준다.

하지만 실제 모델링 측면에서 해당 모델의 가장 큰 문제점은 user와 item 간의 상호작용이 binary하게 인식되는 점, 즉 implicit feedback이 이뤄진다는 점이다. 실제 와인 레이팅 관련 데이터의 경우 0점부터 5점까지의 explicit feedback의 형태인데 반해, 실제로 처리하는 데이터는 상호작용이 있는지 없는지 여부를 판단하는 행렬이기 때문에, 사용자의 해당 item에 대한 선호도를 직접적으로 파악할 수 없다. 이를 데이터 차원에서 해결하기 위해 특정 평점 이하의 상호작용은 0으로 치환하거나, (user, item) 짝을 중복으로 두어 가중치를 반영하는 방법, 혹은 각 점수별로 개별적인 모델들을 만드는 방법들이 있으나 모두 연속적인 explicit feedback 데이터인 와인 레이팅을 반영하기에 어렵거나 비효율적이라는 문제점을 내포하고 있다.

이에 따라 해당 프로젝트에서는 해당 모델을 베이스라인으로 두고 아래의 모델들을 통해 sparse하고 explicit feedback 관련 데이터를 다루고 있는 상황에 대한 해결책을 탐색하고자 한다.

B. MCCF (AAAI 2020)²

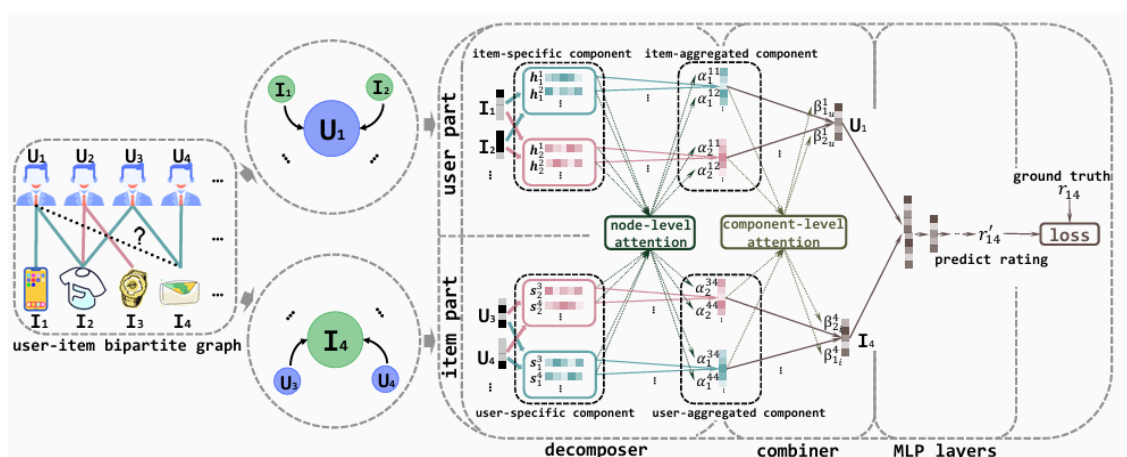


Figure 3. MCCF의 전체 아키텍처

본 프로젝트에서는 사용자에게 개인화된 와인 추천을 제공하기 위해 MCCF(Multi-level Collaborative Filtering) 모델을 사용하였다. MCCF는 전통적인 협업 필터링(Collaborative Filtering)의 한계를 보완하여, 다중 수준(Multi-level)의 관계를 학습할 수 있는 신경망 기반 모델이다. 기존의 행렬 분해

² <Multi-Component Graph Convolutional Collaborative Filtering>, Wang et al., 2019.

방식이 단순한 유저-아이템 상호작용만을 학습하는 반면, MCCF는 아이템 간 유사도, 사용자 간 유사도, 메타 정보 등 다양한 관계 구조를 반영하여 더 정교한 추천 결과를 도출할 수 있다.


MCCF 모델의 구조는 크게 다음 세 부분으로 나뉜다.

첫째, 사용자 및 아이템 정보를 임베딩(Embedding)하여 각각의 벡터 표현으로 변환한다. 둘째, 다양한 관계 정보(예: 사용자-아이템, 아이템-아이템 등)를 다층 퍼셉트론(MLP) 기반의 네트워크에 통합하여 복합적인 상호작용을 학습한다. 셋째, 출력층에서는 예측된 선호 점수 또는 랭킹 점수를 기반으로 추천 리스트를 생성한다. 이 과정에서 BPR(Bayesian Personalized Ranking) 또는 MSE 손실 함수 등을 활용하여 모델을 학습시킨다.

이번 와인 추천 프로젝트에서는 실제로 사용자의 와인 평점 데이터를 기반으로 와이드 포맷을 롱 포맷으로 변환한 뒤, MCCF 모델에 학습 데이터로 입력하였다. 사용자와 와인에 대한 고유 ID를 부여하고, 각 상호작용 데이터를 인덱스 형태로 정제한 후, PyTorch 기반의 WineDataset 클래스와 DataLoader를 통해 학습 효율성을 높였다. 모델 학습은 GPU 환경에서 진행되었으며, 하이퍼파라미터 튜닝을 통해 적절한 임베딩 차원과 레이어 구성을 찾는 과정을 거쳤다.

그 결과, MCCF 모델은 전통적인 CF 기법보다 우수한 성능을 보였으며, 사용자별로 더 정밀하고 의미 있는 와인 추천이 가능해졌다. 이는 단순한 유사도 기반 추천이 아닌, 복합적인 관계를 고려한 딥러닝 기반 접근법의 장점을 잘 보여준다.

C. MKR (WWW 2019)³



(a) Framework of MKR

Figure 4. MKR의 전체 아키텍처

³ <Multi-Task Feature Learning for Knowledge Graph Enhanced Recommendation>, Wang et al., 2019.

MKR(Multi-task feature learning for Knowledge graph enhanced Recommendation)은 전통적인 협업 필터링 방식이 사용자와 아이템 간의 직접적인 상호작용만을 학습하여 희소 데이터 및 cold-start 문제에 취약한 한계를 극복하기 위해 고안된 모델로, 추천 작업과 지식 그래프 임베딩(KGE) 작업을 동시에 학습하는 다중 작업 학습 구조를 채택하고 있다.

이 모델은 사용자와 아이템의 원시 특성을 다층 퍼셉트론(MLP)과 여러 층의 cross&compress unit을 통해 저차원 잠재 벡터로 변환하며, 지식 그래프에서는 (head, relation, tail) 삼중항을 바탕으로 구조적 관계와 의미 정보를 보존하는 임베딩을 생성한다. 특히, cross&compress unit은 아이템과 그에 연관된 KG 엔티티 간의 모든 가능한 고차 상호작용을 명시적으로 모델링함으로써, 두 작업 간의 정밀한 정보 전이를 가능하게 하고 높은 차수의 다항식 근사 능력을 통해 복합 특성을 효과적으로 학습할 수 있도록 한다.

본 프로젝트에서는 이러한 MKR 모델을 기반으로, 와인 추천 데이터의 explicit feedback(평점 0~5점)을 적절히 반영하기 위해 기존의 binary interaction 구조와의 차이를 고려하고, 외부 KG 대신 와인에 대한 도메인 특화 속성(지역, 와이너리, 가격대, 스타일 등)을 활용하여 내부적으로 간단하면서도 의미론적으로 중요한 관계를 구성한 KG를 사용하였다. 또한, 추천 모듈과 KGE 모듈을 서로 다른 빈도로 학습시킴으로써 두 작업에서 모두 우수한 성능을 확보하고, cross&compress unit을 통해 두 모듈 간의 효과적인 정보 전이를 도모하여, 최종적으로 기존 협업 필터링 기반 방식보다 더 정교하고 안정적인 추천 결과를 제공할 수 있도록 모델 구조와 학습 전략을 최적화하였다.

D. KGAT (KDD 2019)⁴

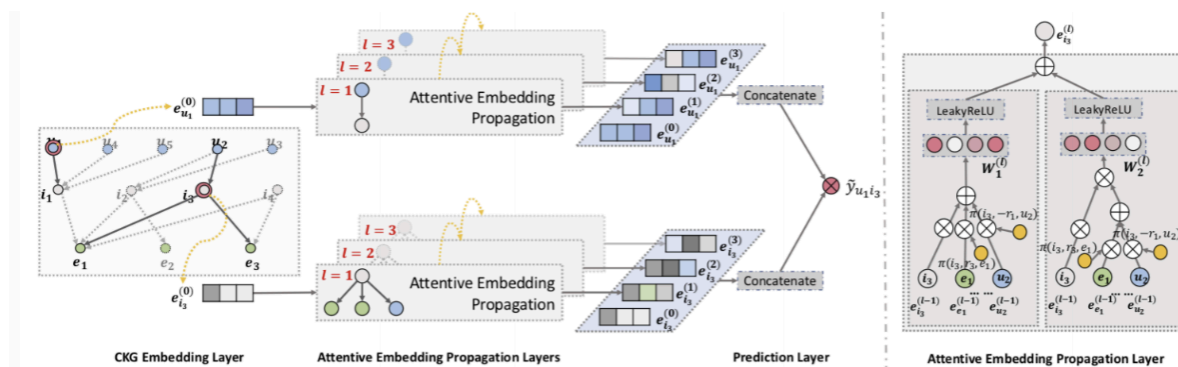


Figure 5. KGAT의 전체 아키텍처.

KGAT(Knowledge Graph Attention Network)는 사용자와 아이템 사이의 상호작용만으로는 표현하기 어려운 잠재적인 의미적 연관성과 관계의 깊이를 모델에 반영하기 위해, 외부의 지식 그래프(Knowledge Graph, KG)를 추천 시스템에 통합한 모델이다. 전통적인 협업 필터링 기반 추천 모델들은 유저와 아이템 간의 직접적인 상호작용(user-item pair)만을 학습에 활용하기 때문에, 데이터가 sparse할 경우 학습이 어렵고, cold-start 사용자나 아이템에 대한 예측 정확도 또한 낮아지는 한계를 지닌다.

⁴ <KGAT: Knowledge Graph Attention Network for Recommendation>, Wang et al., 2019.


이러한 한계를 해결하기 위해 KGAT는 아이템이 포함된 지식 그래프 상의 다양한 이웃 엔티티들(예: 카테고리, 브랜드, 생산지 등)을 활용하여, 아이템의 표현을 더욱 풍부하게 구성한다. 특히 KGAT는 단순히 주변 노드의 정보를 평균화하는 방식이 아니라, 어텐션(attention) 메커니즘을 통해 이웃 엔티티별 중요도를 학습하고, 중요도에 따라 정보를 가중합하는 방식을 채택한다. 이 과정을 통해 모델은 각 아이템마다 어떤 속성 정보가 중요한지를 데이터 기반으로 자동 학습하며, 단순한 이웃 정보 통합보다 더 정교한 표현을 구성할 수 있다.

또한 KGAT는 KG 상에서의 multi-hop 이웃까지 고려할 수 있도록 설계되어 있어, 직접 연결된 노드뿐 아니라 higher-order relations (간접 관계) 도 모델이 학습할 수 있다는 장점이 있다. 예를 들어, 와인 A와 와인 B가 같은 생산지를 공유하고, 그 생산지가 특정 지역에 포함되어 있다면, KGAT는 이러한 간접적인 경로를 통해 와인 A-B 간의 의미적 유사성을 학습할 수 있다. 이러한 구조는 기존 협업 필터링 모델이 놓칠 수 있는 의미 기반 관계를 모델이 인식하고 반영할 수 있게 만든다.

하지만 본 프로젝트에서는 일반적인 KGAT 모델을 그대로 적용하기 어려운 몇 가지 특수성이 존재했다. 첫째, 추천 대상인 와인 데이터는 explicit feedback, 즉 사용자의 평점(0~5점)으로 구성되어 있다. 반면, KGAT는 binary interaction을 전제로 한 모델로, 사용자가 아이템을 "선택했는가/하지 않았는가"의 정보만을 학습에 사용한다. 이로 인해 KGAT는 개별 상호작용의 세기나 선호 정도를 직접적으로 반영하기 어렵고, 평점처럼 연속적인 선호 데이터를 다루는 데에는 한계가 존재한다. 둘째, 기존 KGAT는 Freebase 같은 오픈 지식 데이터베이스에서 가져온 외부 지식 그래프를 기반으로 설계되어 있다. 이러한 그래프는 수많은 엔티티와 관계로 구성되어 있으며, 그 자체로 구조화된 의미 네트워크를 제공한다. 그러나 본 프로젝트에서는 별도의 외부 KG를 사용할 수 없었고, 대신 와인에 대한 속성 정보(지역, 와이너리, 가격대, 스타일 등)를 기반으로 데이터셋 내부에서 엔티티 간 관계를 정의하고 지식 그래프를 구성해야 했다. 즉, 주어진 테이블 형태의 데이터를 활용해 인위적으로 KG를 구성한 셈이며, 이로 인해 그래프 구조는 더 단순하고, 도메인 특화적인 형태를 띈다.

이러한 특수성에 대응하기 위해, 본 프로젝트에서는 기존 KGAT 구조를 기본으로 유지하면서도 다음과 같은 구조적 보완을 통해 모델이 데이터에 보다 적합하게 작동할 수 있도록 조정하였다. 먼저, KGAT의 핵심 구성요소인 attention 메커니즘은 유지하되, 이웃 임베딩을 attention으로 단순 집계하는 대신, 두 층의 MLP를 통해 정제 과정을 추가하였다. 이를 통해 KG 상에서 연결된 이웃 노드 간의 비선형적인 의미 관계까지도 일부 반영할 수 있도록 하였고, 단순한 평균이나 가중합보다 더 정교한 이웃 표현을 만들 수 있었다. 이렇게 정제된 이웃 정보는 아이템의 기본 임베딩과 함께 결합되어, 최종적인 아이템 표현으로 사용된다. 또한, 학습 과정에서는 기존 KGAT에서 사용하는 무작위 negative sampling 대신, hard negative sampling 방식을 적용하였다. 이를 통해 모델이 명확히 구분하지 못하는 어려운 샘플에 더 집중하게 만들었고, 실제 추천 상황에서 발생할 수 있는 fine-grained ranking 문제에 더 효과적으로 대응할 수 있도록 하였다. 마지막으로, explicit feedback을 반영하기 위해, 평점이 일정 수준(예: 4점) 이상인 경우만을 긍정 상호작용으로 간주하는 threshold를 설정하였다. 이는 KGAT의 binary interaction 구조와의 호환성을 유지하면서도, explicit rating 데이터의 연속적인 특성을 일부 반영할 수 있는 실용적인 절충안으로 작용하였다.

E. G-Former (SIGIR 2023)⁵



G-Former(Graph Transformer for Recommendation)는 추천 시스템에서 representation learning을 개선하기 위해 개발된 최신의 접근법으로, Graph Transformer와 generative self-supervised learning(생성적 자기지도학습)을 통합한 모델이다. 기존 GCN 기반 모델들의 한계를 극복하고 explicit feedback 데이터(사용자가 직접 평가한 점수 데이터)와 같은 세부적인 선호도를 반영하기 위한 효과적인 모델로 설계되었다.

기존 Graph Contrastive Learning (GCL) 기반 추천 모델들은 임의적인 그래프 구조 변경을 통해 데이터를 증강시키는 방식을 주로 사용해 왔다. 그러나 이는 중요한 사용자-아이템 관계를 잃거나, 노이즈가 강화될 수 있는 문제점을 내포하고 있다. 이를 해결하기 위해 G-Former는 rationale-aware SSL(이유 기반 자기지도학습)을 통해 자동으로 정보를 추출하여 정교한 데이터 증강을 수행한다.

즉, 추천 모델에 중요한 사용자-아이템 관계를 자동으로 찾아내고, 이를 rationale(이유)로 활용하여 학습 과정에서 데이터의 노이즈를 줄이고 유익한 정보를 선택적으로 학습한다.

G-former는 크게 네 가지 모듈로 이루어져 있다.

- (1) Collaborative Rationale Discovery with Graph Transformer
 - Collaborative rationale(협력적 이유)를 발견하는 모듈이다.
 - Graph Transformer를 활용해 node 사이의 관계(의미적으로 유의미한 사용자-아이템 상호작용)를 자동으로 찾는다.
 - 학습 시 노이즈를 줄이고 필수적인 상호작용만을 골라내는 task-adaptive 방식을 사용한다.
- (2) Global Topology Information Injection
 - 사용자와 아이템 간에 고차적(global) 연결성을 Anchor node라는 기준 노드를 이용하여 포착한다.
 - 이를 통해 생성된 global topological embedding이 Graph Transformer의 입력으로 사용되어 고차적 구조적 정보를 잘 표현한다.

⁵ <Graph Transformer for Recommendation>, Li et al., 2023.

(3) Rational-aware Self-Augmentation

- 발견된 rationale을 기반으로 중요도가 높은 상호작용을 마스킹(masking)하고, Graph Autoencoder로 재구성하여 augmentation(데이터 증강)을 수행한다.
- 무작위 방식이 아니라, 사용자와 아이템 간의 관계를 기반으로 중요성이 큰 부분만을 선택적으로 마스킹하여 고품질의 augmentation을 수행한다.

(4) Complement Independence Regularization

- Rationale과 관계없는 noisy 정보를 독립적으로 구분하여, 상호작용 그래프의 불필요한 정보를 제거하고, 중요한 rationale에만 집중하여 학습을 강화하는 정규화 방식을 채택한다.

G-former는 다음의 목적을 가진 objective function을 통해 학습된다.

- 성능 충분성 (performance sufficiency): rationale(이유)를 통해 얻은 부분 그래프(subgraph)와 원래 그래프 전체의 성능 차이를 최소화
- 상호 독립성 (complement independence): rationale의 보완적 부분(노이즈 포함)과의 의존성을 최소화하여 노이즈의 영향을 억제한다.

3. Results

본 프로젝트에서 모델 평가에 사용한 평가 지표는 다음과 같다.

- 1) **Recall@20**: 사용자가 실제로 상호작용한 아이템이 모델이 추천한 상위 20개 항목 내에 포함된 비율. 추천의 **재현율(Recall)**을 측정.
- 2) **NDCG@20 (Normalized Discounted Cumulative Gain)**: 추천 순위의 품질을 평가. 높은 순위에 실제로 선호된 아이템이 배치될수록 높은 점수.
- 3) **Precision@20**: 추천된 상위 20개 중 실제로 사용자가 좋아한 아이템의 비율. 추천의 정밀도(Precision)를 측정.
- 4) **RMSE (Root Mean Squared Error)**: 예측 평점과 실제 평점 간의 차이를 제곱 평균한 뒤 루트를 씌운 값. 예측의 정량적 오차를 나타냄.

해당 평가 지표를 활용해 모든 모델의 와인 데이터 학습 결과를 평가하였으며, 결과는 다음과 같다.

model	RMSE	Recall@20	NDCG@20	Precision@20
LightGCN	-	0.0490	0.1923	0.1618
KGAT	-	0.0380	0.6736	0.6565
MCCF	1.7732	0.0245	0.0491	0.0478
MKR	-	0.0438	0.2436	0.2275
G-former	0.5896	0.1617	0.8834	0.8654

결과 표를 종합해보면, Gformer 모델이 모든 지표에서 가장 뛰어난 성능을 보였다. Recall@20, NDCG@20, Precision@20에서 모두 최고 점수를 기록하며 사용자 선호를 정확히 반영한 추천이 가능함을 보여주었다. 이는 Gformer가 GCN과 Transformer 구조를 결합하고, Self-supervised learning을 활용해 희소한 데이터에서도 높은 표현력을 확보했기 때문이다. 반면, MCCF는 단일 상호작용만 있는 환경에서 설계된 구조를 충분히 활용하지 못해 상대적으로 낮은 성능을 보였다.

4. Conclusion

4-1) 한계점

본 프로젝트는 데이터 희소성을 극복하고 와인 추천의 정확도를 높이기 위한 다양한 추천 시스템 모델을 적용하고 비교하는 데 목적이 있다. 하지만 다음과 같은 여러 한계점이 존재한다:

1. 데이터 희소성(Sparsity)이 매우 극심함

본 프로젝트에서 사용된 Vivino 데이터셋은 약 30만 개의 와인 정보가 존재하지만, 실제 사용자 수는 466명으로 매우 제한적이며, 각 사용자당 리뷰 수도 적다. 이로 인해 사용자-아이템 상호작용이 매우 희소하며, 이는 대부분의 추천 알고리즘의 성능에 부정적인 영향을 미친다. 일반적인 논문에서 다루는 희소성 수준보다도 훨씬 높은 수준의 sparsity를 다루고 있다.

2. 단일 상호작용(edge) 타입에만 의존함

프로젝트에서 사용한 데이터는 평점(rating)이라는 하나의 관계 유형만 포함하고 있다. 반면, 일부 모델(MCCF, KGAT 등)은 다양한 종류의 상호작용(예: 클릭, 구매, 선호 태그 등)을 동시에 고려하도록 설계되었기 때문에, 데이터의 구조가 해당 모델의 잠재력을 충분히 발휘하지 못하게 하는 제약 요인으로 작용했다.

3. 지식 그래프 사용 시 높은 계산 비용

KGAT, MKR 등의 모델은 대규모 지식 그래프를 활용하여 다양한 속성 정보를 통합하지만, 이를 처리하기 위한 연산량이 크고 학습 시간이 길어 실제 적용 및 실험 반복에 부담이 되었다. 특히 sparse한 환경에서는 추가적인 성능 개선에도 한계가 있었다.

4. 와인 관련 부가 정보의 임베딩 품질 부족

와인의 특성, 맛, 음식 페어링 등 다양한 콘텐츠 기반 정보가 존재하지만, 이들 속성의 텍스트 또는 범주형 정보를 효과적으로 벡터화하는 과정에서 품질 저하가 발생했다. 이로 인해 콘텐츠 기반 요소를 효과적으로 추천에 반영하는 데 어려움이 있었다.

4-2) 기여점

다음과 같은 의의 있는 기여점을 가진다:

1. 와인 도메인 특화 데이터셋 수집 및 벤치마크 구축

대중적인 추천 시스템 연구에서 잘 다루어지지 않았던 와인 추천이라는 도메인에 대해, Vivino 웹사이트로부터 미국 내 상위 500명의 리뷰어 데이터를 직접 수집하고 정제하여 독자적인 벤치마크 데이터셋을 구축하였다. 이는 향후 유사한 분야의 연구에 재사용 가능성이 높은 기초 자료로 기능할 수 있다.

2. 데이터 희소성 문제를 고려한 모델 실험 설계

기존의 추천 시스템 논문들은 대부분 비교적 밀집된 상호작용 데이터를 기반으로 실험을 진행하나, 본 프로젝트는 극도로 희소한 사용자-아이템 행렬을 대상으로 성능을 비교 분석하였다. 이를 통해 실제 상용 서비스에서 발생할 수 있는 cold-start 문제나 데이터 부족 환경에서의 모델 선택 기준을 제시하였다.

3. 다양한 최신 추천 알고리즘에 대한 실험 및 비교

단순 협업 필터링(CF) 기반 모델뿐 아니라, Knowledge Graph 기반(KGAT, MKR), Self-supervised 기반(Gformer), 다중 상호작용 기반(MCCF) 등 최근 연구된 다양한 추천 알고리즘들을 실제 데이터에 적용하고 비교하였다. 이를 통해 각각의 모델이 데이터 구조와 제약 조건에 따라 어떤 성능 차이를 보이는지 실증적으로 평가할 수 있었다.

4. G-former의 효과적인 결과 개선

본 프로젝트에서 적용된 G-Former(Graph-Transformer) 모델은 기존의 추천 시스템 아키텍처들이 직면하던 한계를 효과적으로 극복한 최신 모델로, 특히 희소한 데이터(sparse data) 및 explicit feedback 환경에서 매우 뛰어난 성능을 보여주었다. GCN과 TransformerConv를 결합한 하이브리드 구조를 기반으로, 사용자-아이템 간의 복잡한 관계를 정교하게 학습할 수 있도록 설계되었다. 또한, LightGCN에서 종종 발생하는 over-smoothing 및 overfitting 문제를 효과적으로 억제하고, graph 구조 내에서 의미 있는 관계 정보를 선택적으로 활용할 수 있는 장점도 가지고 있다. 결과적으로 G-Former는 추천 시스템의 정확도뿐 아니라 해석 가능성, 강건성, 일반화 성능까지 모두 확보한 최신 접근법으로서, 실세계 데이터셋(예: 와인 추천)에도 실용적으로 활용될 수 있는 가능성을 확인하였다.